Центральный университет

Курс «Научная студия»

Исследование переноса группового знания в нейронных процессах для cold-start рекомендаций

Group Knowledge Transfer in Neural Processes for Cold-Start Recommendation

Исследовательская работа

Автор: Владимир Лаврентьев
Научный руководитель: Александр Дьяконов

Москва, 2026

Аннотация

Работа посвящена исследованию переноса группового знания в нейронных процессах для рекомендаций пользователям с малой историей взаимодействий. Модели TaNP и FANP используют опыт других пользовательских задач, однако улучшение средних метрик не исключает локального ухудшения рекомендаций, если новый пользователь ошибочно сопоставлен с нерелевантной группой. Цель работы — количественно оценить такой негативный перенос и определить, можно ли выявлять его по доступной истории пользователя и внутренним характеристикам модели. Для этого формируется единый экспериментальный протокол, включающий воспроизведение TaNP и FANP, сопоставимый вариант модели без группового компонента и анализ индивидуальной разницы метрик между режимами с переносом и без него в одинаковых условиях оценки и обучения. На подготовительном этапе воспроизведена открытая реализация TaNP Gating-FiLM на LastFM, MovieLens-1M и реконструированном Gowalla при seed 2020. На последней эпохе получены значения Precision@10, NDCG@10 и MAP@10, равные соответственно 87.42%, 80.81% и 84.95% для LastFM; 62.17%, 75.11% и 50.65% для MovieLens-1M; 62.08%, 60.41% и 45.16% для Gowalla. Результаты LastFM и MovieLens-1M имеют тот же порядок, что и опубликованные показатели TaNP, тогда как Gowalla используется только как внутренний baseline из-за отсутствия точного авторского разбиения данных. Полученный воспроизводимый baseline задаёт контрольную точку для последующего анализа группового компонента на уровне отдельных пользователей; вывод о наличии негативного переноса будет сделан после сравнения с режимом, использующим только личное представление.

Ключевые слова: рекомендательные системы, холодный старт, нейронные процессы, метаобучение, перенос знаний, негативный перенос.

Abstract

This work studies group-knowledge transfer in neural processes for recommending items to users with short interaction histories. TaNP and FANP reuse experience from other user tasks, but improvements in aggregate metrics do not rule out a local degradation when a new user is incorrectly matched to an irrelevant group. The objective is to quantify this negative transfer and determine whether it can be detected from the available user history and the internal characteristics of the model. We define a unified experimental protocol that includes reproducing TaNP and FANP, constructing a comparable model variant without the group component, and analysing per-user metric differences between the transfer and personal-only settings. As a preparatory stage, we reproduced the public TaNP Gating-FiLM implementation on LastFM, MovieLens-1M, and a reconstructed

Gowalla dataset using seed 2020. At the final epoch, the Precision@10, NDCG@10, and MAP@10 values were 87.42%, 80.81%, and 84.95% for LastFM; 62.17%, 75.11%, and 50.65% for MovieLens-1M; and 62.08%, 60.41%, and 45.16% for Gowalla, respectively. The LastFM and MovieLens-1M results are of the same order as the published TaNP results, whereas Gowalla is used only as an internal baseline because the exact authors' data split is not available. This reproducible baseline provides a reference point for analysing the group component at the individual-user level; the presence of negative transfer will be assessed after comparison with the personal-only setting.

Keywords: recommender systems, cold start, neural processes, meta-learning, knowledge transfer, negative transfer.

Содержание

Аннотация **i**

Abstract **i**

1 Введение **1**

2 Обзор литературы **3**

2.1 Метаобучение для холодного старта 3

2.2 Нейронные процессы и task-adaptive-рекомендации 4

2.3 Выбор релевантного знания 5

2.4 Негативный перенос и исследовательский пробел 5

3 Постановка задачи **6**

4 Предлагаемый метод **8**

4.1 Базовая модель TaNP Gating-FiLM 8

4.2 Контроль влияния группового знания 8

4.3 FANP и возможное улучшение 9

5 Вычислительный эксперимент **9**

5.1 Данные и подготовка выборки 9

5.2 Экспериментальный протокол 10

5.3 Метрики 11

6 Результаты и обсуждение **11**

6.1 Воспроизведение TaNP Gating-FiLM 11

7 Заключение **13**

Список литературы **14**

A Дополнительные материалы **17**

1 Введение

Рекомендательные системы опираются на историю взаимодействий пользователя с объектами, поэтому качество персонализации обычно зависит от объёма доступной истории. Для нового пользователя эта история отсутствует или состоит лишь из нескольких взаимодействий. В таком режиме, называемом пользовательским холодным стартом, построить устойчивое представление предпочтений только по личным данным затруднительно. Ошибки на этом этапе особенно существенны: первые рекомендации формируют пользовательский опыт и одновременно определяют, какие новые наблюдения система получит для последующего обучения. Современный обзор методов метаобучения для холодного старта показывает, что проблема остаётся актуальной, а единый стандарт анализа и сравнения предложенных решений ещё не сформировался (Zawia et al., 2025).

Один из распространённых подходов состоит в переносе знаний, полученных на пользователях с достаточной историей, на задачу нового пользователя. В метаобучении каждый пользователь рассматривается как отдельная задача, а модель обучается быстро адаптироваться к новой задаче по небольшому набору наблюдений. MeLU и MetaCS используют для этого общую инициализацию параметров, которую уточняют на взаимодействиях нового пользователя (Lee et al., 2019; Bharadhwaj, 2019). MAMO дополняет эту схему внешней памятью, позволяющей получать более специализированную инициализацию (Dong et al., 2020). Такие методы используют опыт других пользователей как источник априорной информации и в среднем превосходят обучение полностью с нуля, однако их результат зависит от того, насколько переносимое знание соответствует предпочтениям конкретного пользователя.

В TaNP задача переноса решается средствами нейронного процесса (Lin et al., 2021). Модель обучает набор центроидов пользовательских задач, мягко сопоставляет с ними нового пользователя и формирует групповое представление как взвешенную комбинацию центроидов. Затем личное и групповое представления используются для адаптации предиктора. FANP развивает эту схему: использует более гибкое латентное распределение на основе normalizing flow и разделяет task-specific и task-relevant представления при модуляции декодера (Lin et al., 2024). Обе модели показывают, что структурированный перенос между пользовательскими задачами способен улучшать агрегированные метрики рекомендаций.

При этом пользователи могут существенно различаться, а ограниченная история нового пользователя создаёт неопределённость при выборе релевантной группы. Если модель приписывает высокий вес центроиду, который отражает чужие предпочтения, групповое представление потенциально может ухудшить прогноз по сравнению с вариантом, использующим только личную историю. В настоящей работе такой случай называется *негативным переносом группового знания*. Это рабочее операциональ-

ное определение: негативный перенос фиксируется, если при одинаковых данных и условиях оценки добавление группового компонента снижает качество рекомендаций для конкретного пользователя. Существование и масштаб этого эффекта для TaNP и FANP заранее не предполагаются и должны быть установлены экспериментально.

Релевантность переносимого знания уже учитывается в нескольких последующих работах. PAML локально разделяет prior-знание между пользователями с похожими предпочтениями (Wang et al., 2021); AdaML объединяет кластерный и meta-path-подходы для поиска связанных пользователей (Xu et al., 2023); AdaMO адаптирует как инициализацию модели, так и стратегию её обновления (Pu et al., 2024). В более поздней работе планировщик meta-задач использует значение функции потерь и сходство градиентов, чтобы снижать влияние шумных задач (He et al., 2025). Эти результаты подтверждают важность селективного переноса, однако не отвечают непосредственно на вопрос, как часто групповое знание в TaNP и FANP ухудшает результат отдельных пользователей по сравнению с сопоставимым режимом без него и как этот эффект связан с объёмом истории и распределением весов центроидов.

Исследовательский вопрос работы формулируется следующим образом: как перенос группового знания влияет на качество cold-start-рекомендаций для отдельных пользователей и можно ли по доступной истории и внутренним характеристикам модели выявить случаи, в которых такой перенос оказывается неуместным?

Проверяется гипотеза о том, что модель с групповым знанием может уступать сопоставимой модели, использующей только личное представление, для части новых пользователей, особенно при малом числе взаимодействий и ошибочном мягком сопоставлении с центроидами. Гипотеза не утверждает, что TaNP или FANP должны быть хуже в среднем: предполагаемый эффект может быть локальным и поэтому оставаться незаметным в агрегированных метриках.

Цель работы — количественно оценить влияние переноса группового знания в TaNP и FANP на рекомендации новым пользователям и, если устойчивый негативный перенос будет обнаружен, предложить и проверить способ его ограничения. Для достижения цели необходимо решить следующие задачи:

1) воспроизвести базовые результаты TaNP и FANP в едином экспериментальном протоколе;

2) построить сопоставимый вариант без группового компонента и определить индивидуальную разницу метрик между режимами с переносом и без него;

3) проанализировать эту разницу в зависимости от числа доступных взаимодействий, весов центроидов и свойств пользовательских задач;

4) проверить устойчивость наблюдений на нескольких наборах данных и случайных инициализациях;

5) при подтверждении гипотезы разработать способ ограничения неуместного переноса и сравнить его с исходными моделями.

Ожидаемый результат работы состоит не только в сравнении средних значений Precision, NDCG и MAP. Планируется получить воспроизводимую процедуру анализа переноса на уровне отдельных пользователей, описать условия, при которых групповое знание помогает или мешает, и оценить возможность улучшения механизма адаптации. До получения экспериментальных результатов этот вклад следует рассматривать как планируемый, а не как установленное преимущество нового метода.

2 Обзор литературы

2.1 Метаобучение для холодного старта

Методы холодного старта можно условно разделить на подходы, использующие дополнительные признаки, и подходы, переносящие знания между задачами. В первом случае модель строит представление нового пользователя или объекта по демографическим, текстовым либо мультимодальным признакам. Например, DropoutNet имитирует отсутствие коллаборативных признаков во время обучения и учится восстанавливать рекомендации по контентной информации (Volkovs et al., 2017). MTPR переносит мультимодальные признаки новых объектов в пространство, пригодное для ранжирования (Du et al., 2020), а CLCRec согласует контентные и коллаборативные представления с помощью контрастивного обучения (Wei et al., 2021). Эти методы показывают, что внешние признаки способны компенсировать нехватку взаимодействий, но их доступность и информативность зависят от конкретного приложения. Кроме того, MTPR и CLCRec ориентированы преимущественно на холодный старт объектов, тогда как настоящая работа рассматривает новых пользователей.

Метаобучение предлагает другой взгляд: вместо построения одной модели по всем наблюдениям система обучается быстро решать новую задачу по малому support-набору. Одна из первых работ в рекомендациях сформулировала item cold start как последовательность задач метаобучения (Vartak et al., 2017). Для пользовательского cold start MeLU и MetaCS рассматривают каждого пользователя как отдельную задачу и адаптируют общую инициализацию по нескольким взаимодействиям (Lee et al., 2019; Bharadhwaj, 2019). Такая схема следует идее MAML: параметры выбираются так, чтобы несколько градиентных шагов давали хорошее решение новой задачи (Finn et al., 2017). S2Meta расширяет постановку на последовательные и зависящие от сценария онлайн-рекомендации (Du et al., 2019).

Общая инициализация не всегда отражает неоднородность предпочтений. Поэтому последующие методы стали переносить более локальное знание. MAMO использует внешнюю память для получения персонализированных начальных параметров

(Dong et al., 2020). MetaHIN формирует задачи с учётом семантики гетерогенной информационной сети и совместно адаптирует представления и предиктор (Lu et al., 2020). CMML заменяет дорогостоящий внутренний цикл контекстной модуляцией параметров (Feng et al., 2021). Общая тенденция этих работ состоит в переходе от единого prior-знания к параметрам, зависящим от пользователя или контекста задачи.

2.2 Нейронные процессы и task-adaptive-рекомендации

Нейронные процессы объединяют свойства нейронных сетей и вероятностных моделей функций. По небольшому контекстному набору они строят представление задачи и амортизированно формируют предсказания в новых точках (Garnelo et al., 2018a). Conditional Neural Process реализует эту схему через кодирование и агрегацию контекстных пар (Garnelo et al., 2018b). Простая агрегация может терять информацию о структуре контекста, поэтому Attentive Neural Process делает представление зависимым от точки запроса с помощью attention (Kim et al., 2019). Другие варианты адаптации включают условную генерацию параметров в CNAPS (Requeima et al., 2019) и итеративные функциональные обновления в MetaFun (Xu et al., 2020). Эти архитектуры важны для рекомендаций, поскольку support-набор взаимодействий пользователя естественно интерпретируется как контекст, определяющий его функцию предпочтений.

TaNP переносит нейронный процесс на пользовательский cold start и дополняет его task-adaptive-механизмом (Lin et al., 2021). Пользовательские задачи мягко сопоставляются с обучаемыми центроидами, из которых формируется task-relevant-представление. Оно объединяется с личным представлением задачи и модулирует предиктор. Один из вариантов TaNP использует FiLM — покомпонентное масштабирование и сдвиг скрытых признаков условными параметрами (Perez et al., 2018). В отличие от градиентной адаптации MAML, такой механизм работает за один прямой проход после построения представления пользователя.

FANP развивает TaNP в двух направлениях (Lin et al., 2024). Во-первых, normalizing flow заменяет ограниченное гауссово приближение латентной переменной. Во-вторых, личное и связанное с группой представления поступают в механизм адаптации раздельно, благодаря чему декодер может учитывать их по-разному. Авторы показывают улучшение средних метрик и устойчивость при сокращении support-набора. Однако сравнение проводится преимущественно на уровне агрегированных результатов. Из него нельзя определить, помогает ли групповой компонент каждому пользователю и компенсирует ли обучаемая модуляция случаи ошибочного сопоставления с центроидами.

2.3 Выбор релевантного знания

Идея о том, что разным задачам требуется различное prior-знание, получила прямое развитие в relevance-aware-методах. PAML использует социальные связи и структуру user–item–attribute для поиска пользователей с близкими предпочтениями, после чего строит preference-specific prior (Wang et al., 2021). Работа также отмечает, что добавление слишком большого числа неявных соседей может привнести шум. AdaML сочетает кластерный и meta-path-подходы, динамически взвешивает найденных связанных пользователей и использует их как для улучшения представления, так и для настройки prior (Xu et al., 2023). Оба метода подтверждают полезность локального переноса, но предполагают наличие дополнительных социальных или гетерогенных связей.

AdaMO адаптирует не только начальное знание, но и способ обновления модели при переходе от cold-start- к warm-up-этапу (Pu et al., 2024). Это позволяет учитывать изменение предпочтений, однако добавляет сложный механизм перехода и не изолирует влияние группового компонента на отдельных пользователей. Dual Enhanced Meta-Learning использует loss и сходство градиентов для управления вероятностью выбора meta-задач (He et al., 2025). По смыслу этот подход наиболее близок к предотвращению неуместного переноса: задачи, которые дают противоречивый или шумный сигнал, реже участвуют в обучении. Тем не менее планировщик действует на уровне обучающих задач, а не на уровне центроидов, используемых при адаптации конкретного нового пользователя.

Систематический обзор meta-learning-методов cold start также выделяет адаптивный выбор переносимого знания и согласование обучающих задач как перспективные направления (Zawia et al., 2025). В то же время существующие сравнения главным образом отвечают на вопрос, какой метод имеет лучшее среднее качество. Для прикладной системы этого недостаточно: одинаковое улучшение средней метрики может сочетаться как с небольшим выигрышем почти для всех пользователей, так и с сильным выигрышем одной группы при ухудшении другой.

2.4 Негативный перенос и исследовательский пробел

Проблема конфликтующего знания изучается в смежной постановке multi-task learning. PCGrad определяет конфликт через противоположно направленные градиенты задач и удаляет компонент обновления, мешающий другой задаче (Yu et al., 2020). Этот результат не переносится на TaNP и FANP напрямую: центроиды участвуют в формировании представления пользователя, а не являются отдельными оптимизируемыми задачами в момент предсказания. Тем не менее градиентное сходство даёт содержательный диагностический признак, который можно сопоставить с весами центроидов и индивидуальным изменением качества.

Проведённый обзор показывает, что сама идея адаптивного или локального переноса не является новой. TaNP и FANP обучают task-relevant-представление, PAML и AdaML ищут связанных пользователей, AdaMO адаптирует перенос по фазе обучения, а Dual Enhanced Meta-Learning фильтрует шумные задачи. Незакрытым остаётся более конкретный вопрос: существуют ли в TaNP и FANP пользователи, для которых групповой компонент ухудшает рекомендации относительно сопоставимого режима только с личным представлением, насколько часто это происходит и связано ли ухудшение с малым support-набором, неопределёнными весами или выбором нерелевантного центроида. Настоящая работа сначала измеряет этот эффект в воспроизводимом эксперименте и только при его устойчивом обнаружении переходит к разработке корректирующего механизма.

3 Постановка задачи

Пусть U — множество пользователей, V — множество объектов, а $y_{i,j}$ — наблюдавшаяся реакция пользователя i на объект j. В зависимости от набора данных реакцией является явная оценка либо бинарная метка взаимодействия. Каждый пользователь задаёт отдельную задачу

$$T_i = (S_i, Q_i),$$

где S_i — support-набор доступных модели взаимодействий, а Q_i — query-набор, на котором оцениваются рекомендации. Число доступных взаимодействий обозначается как

$$N_{S_i} = |S_i|.$$

Элемент support-набора представляет собой пару признаков пользователя и объекта $x_{i,j}$ и целевой реакции $y_{i,j}$. В базовом протоколе $N_{S_i} = 20$, а в дополнительном анализе размер истории будет сокращаться, чтобы исследовать более строгий режим холодного старта. Пользователи разделяются на непересекающиеся множества meta-train, validation и meta-test; следовательно, на этапе тестирования модель получает задачи пользователей, которые не участвовали в её обучении.

Кодировщик задачи строит личное представление пользователя

$$t_i = \frac{1}{|S_i|} \sum_{(x,y)\in S_i} h_{task}(x, y).$$

В TaNP дополнительно обучается набор из k центроидов пользовательских задач

$$A = [a_1, \ldots, a_k].$$

Для пользователя i вычисляются веса мягкого сопоставления $c_i = (c_{i,1}, \ldots, c_{i,k})$. В реализованной версии ненормированные и нормированные веса задаются как

$$q_{i,j} = \left(1 + \frac{\|t_i - a_j\|_2}{\tau}\right)^{-(\tau+1)/2},$$

$$c_{i,j} = \frac{q_{i,j}}{\sum_{l=1}^{k} q_{i,l}}.$$

Здесь τ — температура сопоставления. Групповое знание представляет собой взвешенную комбинацию центроидов

$$o_i = A c_i^{\top},$$

а в TaNP адаптивное представление имеет вид $t_i + o_i$. Вместе с латентным представлением предпочтений оно передаётся декодеру, который присваивает оценки объектам из Q_i и формирует их ранжирование.

Основное сравнение проводится между двумя режимами одной архитектуры:

- **group** — исходный режим, использующий $t_i + o_i$;
- **personal** — контрольный режим, в котором $o_i = 0$ и предиктор получает только t_i.

Для пользователя i, метрики m и глубины ранжирования K индивидуальный эффект переноса определяется как

$$\Delta_i^{m,K} = m_i^{group}@K - m_i^{personal}@K.$$

Негативным переносом для данной метрики называется случай $\Delta_i^{m,K} < 0$. Анализируются доля таких пользователей, среднее значение $\Delta_i^{m,K}$, условное среднее ухудшение среди пользователей с отрицательным эффектом и зависимость эффекта от N_{S_i} и вектора c_i. Основными внешними метриками являются Precision@K, NDCG@K и MAP@K для $K \in \{5, 7, 10\}$; во всех трёх случаях большее значение соответствует более качественному ранжированию.

Первая проверяемая гипотеза состоит в том, что распределение $\Delta_i^{m,K}$ может содержать устойчивую отрицательную часть, даже если его среднее неотрицательно. Вторая гипотеза связывает отрицательный эффект с неопределённым либо ошибочным сопоставлением пользователя с центроидами. Обе гипотезы проверяются на meta-test-пользователях и не считаются доказанными до получения воспроизводимых результатов на нескольких наборах данных.

4 Предлагаемый метод

4.1 Базовая модель TaNP Gating-FiLM

Воспроизводимый бейзлайн следует опубликованной архитектуре TaNP (Lin et al., 2021). Сначала отдельные признаки объекта и пользователя преобразуются обучаемыми embedding-слоями. Латентный кодировщик по контекстным парам формирует параметры распределения предпочтений и выбирает латентный вектор z_i. Параллельный task encoder строит личное представление t_i. Memory unit сопоставляет его с обучаемыми центроидами A, вычисляет c_i и возвращает сумму $t_i + o_i$.

Декодер получает признаки объекта, латентный вектор и адаптивное представление задачи. В варианте Gating-FiLM для каждого скрытого слоя по представлению задачи вычисляются параметры масштаба, сдвига и gate. Gate выбирает, насколько сильно использовать task-specific FiLM-параметры или общий альтернативный сигнал. Таким образом, архитектура способна адаптировать сразу несколько уровней предиктора без внутреннего цикла градиентных шагов.

Функция обучения состоит из ошибки предсказания, KL-согласования латентных распределений support- и target-наборов и кластеризующего слагаемого:

$$L = L_{pred} + D_{KL}(p_{target}, p_{support}) + \lambda L_{cluster}.$$

Кластеризующее слагаемое усиливает уверенное распределение задач по центроидам, а коэффициент λ регулирует его вклад. В базовом запуске используются $k = 10$, $\tau = 1$ и $\lambda = 1$, что соответствует авторскому скрипту обучения.

4.2 Контроль влияния группового знания

Первое расширение не вводит новую обучаемую архитектуру, а добавляет контролируемую абляцию. Для одного и того же пользователя и одного query-набора сохраняются предсказания исходного режима и режима $o_i = 0$. Использование одинаковых весов, данных и случайного латентного состояния позволяет отделить непосредственный эффект группового компонента от различий, возникающих при обучении двух независимых моделей. Дополнительно планируется обучить personal-only-вариант отдельно, чтобы проверить, сохраняется ли вывод после полной перенастройки параметров без группового пути.

Для каждого meta-test-пользователя будут сохранены метрики обоих режимов, вектор c_i, выбранный центроид, энтропия весов и размер support-набора. Такой формат позволяет перейти от одной средней метрики к распределению эффектов и выделить группы пользователей, для которых перенос помогает или мешает.

4.3 FANP и возможное улучшение

На втором этапе тот же анализ применяется к FANP (Lin et al., 2024). Это позволит проверить, устраняет ли раздельная task-adaptive-модуляция эффект, который может наблюдаться в TaNP. FANP рассматривается как более сильный бейзлайн, а не как предлагаемая нами модель.

Собственный корректирующий механизм будет определён только после диагностики. Если негативный перенос окажется устойчивым, минимальное улучшение должно уменьшать вклад o_i при признаках ненадёжного сопоставления и сохранять его, когда центроиды полезны. Кандидатами на управляющий сигнал являются энтропия c_i, расстояние до ближайшего центроида и согласованность градиентов задач. До проведения анализа выбор конкретного сигнала и утверждение об улучшении не фиксируются, чтобы метод следовал из наблюдаемого эффекта, а не из заранее принятого предположения.

5 Вычислительный эксперимент

5.1 Данные и подготовка выборки

Используются три набора данных из экспериментальной части TaNP. Это LastFM, MovieLens-1M и Gowalla. Их подготовленные характеристики приведены в таблице 1.

Таблица 1: Наборы данных до формирования пользовательских эпизодов

Набор данных	Пользователи	Объекты	Взаимодействия
LastFM	1,872	3,846	42,346
MovieLens-1M	6,040	3,706	1,000,209
Gowalla	2,692	32,895	208,280

LastFM берётся из архива исходного репозитория TaNP. MovieLens-1M загружается из официального архива GroupLens; идентификаторы пользователей и фильмов перенумеровываются с нуля, оценки сохраняются без дополнительного преобразования. Авторы TaNP не опубликовали готовые MovieLens-эпизоды, поэтому совпадение пользовательского разбиения обеспечивается доступным кодом и seed, но полное совпадение с неизвестным авторским препроцессингом не гарантируется.

Для Gowalla точный подготовленный датасет и negative sampling также не опубликованы. Используется детерминированная реконструкция из открытого разбиения NGCF: выбираются пользователи с 20–100 положительными объектами, для каждого положительного взаимодействия добавляется один непросмотренный объект с меткой 0, после чего выборка ограничивается 2,692 пользователями. Поэтому результат Gowalla предназначен для внутреннего сравнения вариантов в одинаковых

условиях, а не для утверждения о точном воспроизведении числа из исходной статьи.

При seed 2020 пользователи случайно разделяются в пропорции 70%/10%/20% на meta-train, validation и meta-test. Объекты, не встречавшиеся у обучающих пользователей, удаляются из тестовых задач. Пользователь включается в эпизоды, если после фильтрации имеет от 30 до 200 взаимодействий. Первые 20 элементов случайной перестановки образуют support-набор, оставшиеся — query-набор. Параметр `query_size=10` задаёт минимально необходимый остаток истории; в текущей авторской реализации query-набор не обрезается до десяти элементов. Эта особенность фиксируется как часть воспроизводимого протокола.

5.2 Экспериментальный протокол

Первый этап воспроизводит TaNP Gating-FiLM отдельно на каждом наборе данных. Размеры embedding-слоёв равны 32 и 16, размеры латентного пути — 32, 32 и 32, размеры task encoder — 32, 32 и 16, размеры трёх скрытых слоёв декодера — 32, 32 и 16. Используются 10 центроидов, температура 1, коэффициент кластеризующей потери 1 и нулевой dropout. Оптимизатор Adam работает с learning rate 10^{-4} и batch size 32 в течение 100 эпох. Эти параметры совпадают с `third_party/TaNP/train.sh`; дополнительно явно выбирается реализованный авторами декодер Gating-FiLM.

Базовое воспроизведение проводится с seed 2020, использованным в исходном коде. Этот запуск нужен для сопоставления с опубликованной таблицей, но его недостаточно для вывода об устойчивости. После получения базового результата ключевые сравнения group и personal должны быть повторены как минимум на трёх seed; в итоговой версии будут приведены среднее и стандартное отклонение.

Обучение выполняется последовательно для трёх датасетов на NVIDIA T4 в Google Colab. Конфигурация, команда, версия Python, версия PyTorch, версия CUDA и название GPU записываются в `run_metadata.json`. Каждые пять эпох атомарно сохраняется промежуточный checkpoint, содержащий параметры модели, состояние Adam, номер эпохи, порядок пользовательских задач и состояния генераторов Python, NumPy, PyTorch и CUDA. После разрыва Colab запуск продолжается со следующей эпохи без удаления уже записанных строк лога. Завершённым считается только запуск, имеющий итоговый файл модели и лог обучения.

Для каждого датасета сохраняются значения метрик после каждой эпохи. Базовая таблица формируется единым запуском из трёх итоговых моделей. Выбор лучшей эпохи по тестовым данным не проводится: основной результат соответствует последней, сотой эпохе. Сформированное кодом validation-разбиение пока не используется для early stopping, что повторяет текущую реализацию и явно фиксируется как ограничение протокола.

5.3 Метрики

Precision@K — доля релевантных объектов среди первых K позиций. NDCG@K также учитывает порядок и степень релевантности: ошибки в начале списка штрафуются сильнее. MAP@K усредняет precision в позициях, на которых встречаются релевантные объекты, и характеризует качество порядка во всей верхней части выдачи. В соответствии с TaNP вычисляются значения при $K \in \{5, 7, 10\}$ и затем усредняются по meta-test-пользователям.

Для проверки гипотезы агрегированных метрик недостаточно. Поэтому для каждой метрики дополнительно рассчитываются распределение $\Delta_i^{m,K}$, доля пользователей с $\Delta_i^{m,K} < 0$, медиана эффекта и условное среднее ухудшение. Результаты стратифицируются по размеру support-набора и свойствам c_i. Главной метрикой анализа переноса выбирается NDCG@10 как чувствительная к порядку ранжирования; Precision@10 и MAP@10 используются для проверки, что вывод не является особенностью одной метрики.

6 Результаты и обсуждение

6.1 Воспроизведение TaNP Gating-FiLM

На текущем этапе завершены запуски на LastFM, MovieLens-1M и реконструированном Gowalla. Для каждого набора данных модель обучалась 100 эпох с seed 2020; в таблицу включены метрики последней эпохи, без выбора лучшего результата по тестовой выборке. Результаты сопоставляются с опубликованными значениями TaNP Gating-FiLM (Lin et al., 2021). Все значения приведены в процентах.

Таблица 2: Сравнение воспроизведённого TaNP Gating-FiLM с результатами статьи

Датасет	Источник	K	P@K	NDCG@K	MAP@K
MovieLens-1M	Статья	5	60.12	75.00	49.12
MovieLens-1M	Наш запуск	5	58.97	74.56	48.55
MovieLens-1M	Статья	7	60.29	75.34	50.79
MovieLens-1M	Наш запуск	7	59.68	74.59	48.38
MovieLens-1M	Статья	10	62.66	75.53	51.56
MovieLens-1M	Наш запуск	10	62.17	75.11	50.65
LastFM	Статья	5	76.36	77.18	70.12
LastFM	Наш запуск	5	76.67	77.23	71.22
LastFM	Статья	7	79.00	77.30	73.92
LastFM	Наш запуск	7	77.27	75.63	73.11
LastFM	Статья	10	88.64	82.10	85.94
LastFM	Наш запуск	10	87.42	80.81	84.95
Gowalla (реконструкция)	Наш запуск	5	61.30	59.42	46.72
Gowalla (реконструкция)	Наш запуск	7	61.97	60.18	45.85
Gowalla (реконструкция)	Наш запуск	10	62.08	60.41	45.16

На LastFM отклонение по девяти метрикам находится в диапазоне от -1.73 до $+1.10$ процентного пункта. При $K = 5$ воспроизведённый результат немного выше опубликованного, а при $K = 7$ и $K = 10$ — ниже. На MovieLens-1M все девять значений ниже результатов статьи; наибольшее расхождение наблюдается для MAP@7 и составляет -2.41 процентного пункта. При этом различия по P@10 и NDCG@10 не превышают половины процентного пункта.

Полученные значения подтверждают, что реализация обучается и достигает качества того же порядка, однако не являются точным воспроизведением таблиц статьи. В статье указаны 150 эпох и learning rate $5 \cdot 10^{-5}$, а гиперпараметры выбираются по validation-набору. Публичный скрипт, положенный в основу текущего запуска, использует 100 эпох, learning rate 10^{-4}, $k = 10$ и $\lambda = 1$. Кроме того, опубликованный эксперимент MovieLens-1M использует контентные признаки из подготовленных данных MeLU, тогда как в текущем запуске выборка реконструирована из официального MovieLens-1M.

Таким образом, текущий результат следует интерпретировать как воспроизведение открытого кода TaNP в зафиксированном протоколе, а не как точную репликацию опубликованной таблицы. Все три запуска пока выполнены только с одним seed, поэтому различия нельзя отделить от вариативности обучения. Для реконструированного Gowalla получены P@10 62.08%, NDCG@10 60.41% и MAP@10 45.16%. Эти значения фиксируют третий baseline для дальнейших сравнений вариантов модели, но не сопоставляются напрямую с таблицей статьи: точный авторский сплит и процедура negative sampling не опубликованы, а характеристики реконструированной выборки

отличаются от описанных в статье.

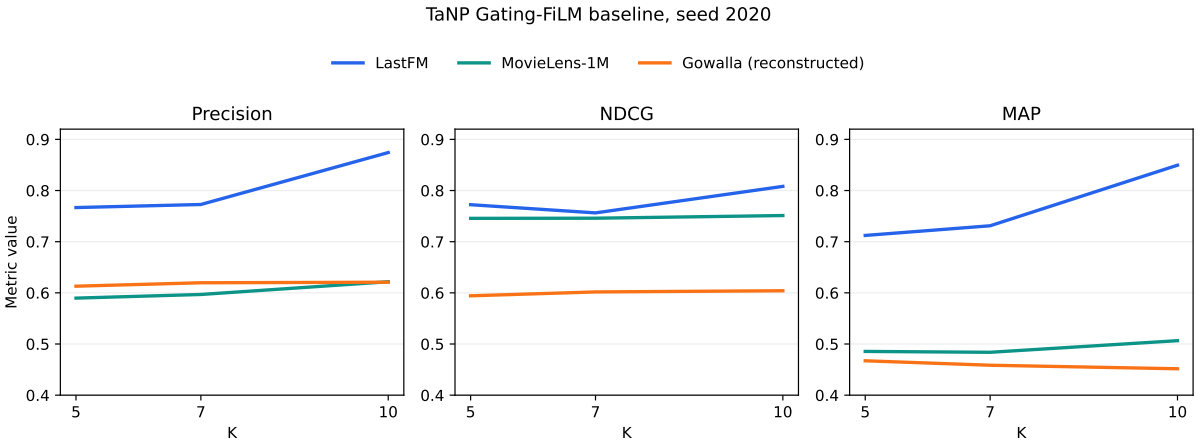


Рис. 1: Метрики TaNP Gating-FiLM на последней эпохе трёх запусков с seed 2020. Результат Gowalla получен на реконструированной выборке.

7 Заключение

[Главные выводы и направления дальнейшей работы.]

Список литературы

Homanga Bharadhwaj. Meta-learning for user cold-start recommendation. In *2019 International Joint Conference on Neural Networks*, pages 1–8, 2019. doi: 10.1109/IJCNN.2019.8852100.

Manqing Dong, Feng Yuan, Lina Yao, Xiwei Xu, and Liming Zhu. MAMO: Memory-augmented meta-optimization for cold-start recommendation. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 688–697, 2020. doi: 10.1145/3394486.3403113.

Xiaoyu Du, Xiang Wang, Xiangnan He, Ziwei Li, Jie Tang, and Tat-Seng Chua. How to learn item representation for cold-start multimedia recommendation? In *Proceedings of the 28th ACM International Conference on Multimedia*, pages 3469–3477, 2020. doi: 10.1145/3394171.3413766.

Zhengxiao Du, Xiaowei Wang, Hongxia Yang, Jingren Zhou, and Jie Tang. Sequential scenario-specific meta learner for online recommendation. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 2895–2904, 2019. URL `https://dl.acm.org/doi/10.1145/3292500.3330710`.

Xidong Feng, Chen Chen, Dong Li, Mengchen Zhao, Jianye Hao, and Jun Wang. CMML: Contextual modulation meta learning for cold-start recommendation. In *Proceedings of the 30th ACM International Conference on Information and Knowledge Management*, pages 484–493, 2021. URL `https://dl.acm.org/doi/10.1145/3459637.3482238`.

Chelsea Finn, Pieter Abbeel, and Sergey Levine. Model-agnostic meta-learning for fast adaptation of deep networks. In *Proceedings of the 34th International Conference on Machine Learning*, volume 70 of *Proceedings of Machine Learning Research*, pages 1126–1135, 2017. URL `https://proceedings.mlr.press/v70/finn17a.html`.

Marta Garnelo, Dan Rosenbaum, Chris J. Maddison, Tiago Ramalho, David Saxton, Murray Shanahan, Yee Whye Teh, Danilo J. Rezende, and S. M. Ali Eslami. Neural processes. *arXiv preprint arXiv:1807.01622*, 2018a. URL `https://arxiv.org/abs/1807.01622`.

Marta Garnelo, Jonathan Schwarz, Dan Rosenbaum, Fabio Viola, Danilo J. Rezende, S. M. Ali Eslami, and Yee Whye Teh. Conditional neural processes. In *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 1704–1713, 2018b. URL `https://proceedings.mlr.press/v80/garnelo18a.html`.

Dongxiao He, Jiaqi Cui, Xiaobao Wang, Guojie Song, Yuxiao Huang, and Lingfei Wu. Dual enhanced meta-learning with adaptive task scheduler for cold-start recommendation.

IEEE Transactions on Knowledge and Data Engineering, 37(4):1728–1741, 2025. doi: 10.1109/TKDE.2025.3529525.

Hyunjik Kim, Andriy Mnih, Jonathan Schwarz, Marta Garnelo, S. M. Ali Eslami, Dan Rosenbaum, Oriol Vinyals, and Yee Whye Teh. Attentive neural processes. In *International Conference on Learning Representations*, 2019. URL https://openreview.net/forum?id=SkE6PjC9KX.

Hoyeop Lee, Jinbae Im, Seongwon Jang, Hyunsouk Cho, and Sehee Chung. MeLU: Meta-learned user preference estimator for cold-start recommendation. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 1073–1082, 2019. doi: 10.1145/3292500.3330859.

Xixun Lin, Jia Wu, Chuan Zhou, Shirui Pan, Yanan Cao, and Bin Wang. Task-adaptive neural process for user cold-start recommendation. In *Proceedings of the Web Conference 2021*, pages 1306–1316, 2021. doi: 10.1145/3442381.3449908. URL https://arxiv.org/abs/2103.06137.

Xixun Lin, Jia Wu, Chuan Zhou, Lixin Zou, Shirui Pan, Yanan Cao, Bin Wang, Shuaiqiang Wang, and Dawei Yin. Towards flexible and adaptive neural process for cold-start recommendation. *IEEE Transactions on Knowledge and Data Engineering*, 36(4): 1813–1828, 2024. doi: 10.1109/TKDE.2023.3304839.

Yuanfu Lu, Yuan Fang, and Chuan Shi. Meta-learning on heterogeneous information networks for cold-start recommendation. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 1563–1573, 2020. doi: 10.1145/3394486.3403207.

Ethan Perez, Florian Strub, Harm de Vries, Vincent Dumoulin, and Aaron Courville. FiLM: Visual reasoning with a general conditioning layer. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 32, pages 3942–3951, 2018. doi: 10.1609/aaai.v32i1.11671.

Juhua Pu, Yuanhong Wang, Fang Nan, and Xingwu Liu. AdaMO: Adaptive meta-optimization for cold-start recommendation. *Neurocomputing*, 580:127417, 2024. doi: 10.1016/j.neucom.2024.127417.

James Requeima, Jonathan Gordon, John Bronskill, Sebastian Nowozin, and Richard E. Turner. Fast and flexible multi-task classification using conditional neural adaptive processes. In *Advances in Neural Information Processing Systems*, volume 32, pages 7957–7968, 2019. URL https://proceedings.neurips.cc/paper/2019/hash/6e2713a6efee97bacb63e52c54f0ada0-Abstract.html.

Manasi Vartak, Arvind Thiagarajan, Conrado Miranda, Jeshua Bratman, and Hugo Larochelle. A meta-learning perspective on cold-start recommendations for items. In *Advances in Neural Information Processing Systems*, volume 30, pages 6904–6914, 2017. URL https://proceedings.neurips.cc/paper/2017/hash/51e6d6e679953c6311757004d8cbbba9-Abstract.html.

Maksims Volkovs, Guangwei Yu, and Tomi Poutanen. DropoutNet: Addressing cold start in recommender systems. In *Advances in Neural Information Processing Systems*, volume 30, pages 4957–4966, 2017. URL https://proceedings.neurips.cc/paper/2017/hash/dbd22ba3bd0df8f385bdac3e9f8be207-Abstract.html.

Li Wang, Binbin Jin, Zhenya Huang, Hongke Zhao, Defu Lian, Qi Liu, and Enhong Chen. Preference-adaptive meta-learning for cold-start recommendation. In *Proceedings of the Thirtieth International Joint Conference on Artificial Intelligence*, pages 1607–1614, 2021. URL https://www.ijcai.org/proceedings/2021/222.

Yinwei Wei, Xiang Wang, Qi Li, Liqiang Nie, Yan Li, Xuan Li, and Tat-Seng Chua. Contrastive learning for cold-start recommendation. In *Proceedings of the 29th ACM International Conference on Multimedia*, pages 5382–5390, 2021. doi: 10.1145/3474085.3475665.

Jia Xu, Hongming Zhang, Xin Wang, and Pin Lv. AdaML: An adaptive meta-learning model based on user relevance for user cold-start recommendation. *Knowledge-Based Systems*, 279:110925, 2023. doi: 10.1016/j.knosys.2023.110925.

Jin Xu, Jean-Francois Ton, Hyunjik Kim, Adam R. Kosiorek, and Yee Whye Teh. MetaFun: Meta-learning with iterative functional updates. In *Proceedings of the 37th International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pages 10617–10627, 2020. URL https://proceedings.mlr.press/v119/xu20b.html.

Tianhe Yu, Saurabh Kumar, Abhishek Gupta, Sergey Levine, Karol Hausman, and Chelsea Finn. Gradient surgery for multi-task learning. In *Advances in Neural Information Processing Systems*, volume 33, pages 5824–5836, 2020. URL https://proceedings.neurips.cc/paper/2020/hash/3fe78a8acf5fda99de95303940a2420c-Abstract.html.

Jamallah M. Zawia, Maizatul Akmar Binti Ismail, Mohammad Imran, Buce Trias Hanggara, Diva Kurnianingtyas, Silvi Asna, and Quang Tran Minh. Comprehensive review of meta-learning methods for cold-start issue in recommendation systems. *IEEE Access*, 13:24622–24641, 2025. doi: 10.1109/ACCESS.2025.3536025.

A Дополнительные материалы

[Материалы, которые важны для воспроизводимости, но перегружают основной текст.]